# 編譯器製作 Homework 1

# Readme of Simple Java - Scanner

Lex 版本:

```
$ lex --version
flex 2.6.4
```

作業平台:

Ubuntu 22.04.2 LTS

執行方式:

```
$ make
flex B093040024.l
gcc lex.yy.c -o demo -lfl
$ ./demo < Test2.java
```

```
makefile

1 FILE_lex = B093040024.l
2 PROG_lex = lex.yy.c
3 all: $(PROG_lex)
4    gcc $(PROG_lex) - o demo -lfl
5
6 $(PROG_lex): $(FILE_lex)
7    flex $(FILE_lex)
8
9 clean:
10    rm demo $(PROG_lex)
```

如何處理這份規格書上的問題:

# 1. Symbols

# symbol [,:;\(\)\{\}\[\]]

若辨識到[...]中任一字元‧則將此 symbol 傳回給 parser‧其中「(」、「)」、「[」、「]」、「{」和「}」為特殊字元‧前面須加上跳脫字元\。

#### 2. Operators

# operator \+\+|--|==|>=|<=|!=|&&|\|\||<|>>>>|[+\-\*\/%=<>!&|^~]

前半部分是將需要兩個以上字元表示的 operator 以|符號連接,代表只要 match 到任一個即可。接著以|符號連接[...],[...]中放的是單一字元的 operator。其中「+」、「-」、「|」、「/」等特殊字元前面須加上跳脫字元\。

#### 3. Reserved Words

```
reserve_word abstract|boolean|break|byte|case|catch|char|class|
const|continue|default|do|double|else|extends|false|final|
finally|float|for|goto|if|implements|import|instanceof|int|
interface|long|main|native|new|package|print|private|protected|
public|return|short|static|string|super|switch|synchronized|
this|throw|throws|transient|true|try|void|volatile|while
```

Java 的 reserved words 都是由兩個字元以上字元組成,將這些 reserved words 以|符號連接,代表只要 match 到任一個即可。

#### 4. Identifiers

# id [A-Za-z\_\\$][A-Za-z0-9\_\\$]\*

Java 的 identifier 第一個字元可以是一個大寫或小寫的英文字母,也可以是「\_」或「\$」符號,因此將這些符號放入[...]中。後面的字元可以是英數字或「\_」、「\$」符號,且字數不限,因此將這些符號放入[...]中,並在後面加上\*,表示重複  $0-\infty$ 次。

# invalid\_id [0-9^#]+[a-zA-Z\_\\$]+

不合法的 identifier 可能為數字開頭,或是以「^」、「#」開頭,因此將這些符號放入[...]中,並在後面加上+,表示至少出現一次。

# 5. Integer Constants

# integer ([+-][ ]\*)?(((0[Xx])[A-Fa-f0-9]+)|([0-9]+))

整數的符號和數值之間可能存在多個空格,以[]\*表示,若是正數可不加「+」,因此將辨識正負號與空格的部分以(...)括起來,並在後面加上?,代表括號內的內容可出現 1 次或 0 次。接著可以加上「0x」或「0X」,表示十六進位。數字則出現至少一個,因此在[0-9]後面加上+。

#### 6. Float Constants

### float ([+-][ ]\*)?([0-9]\*\.[0-9]+)|([0-9]+\.[0-9]\*)|[0-9]+([Ee][+-]?[0-9]+)?[Ff]?

浮點數判斷符號和空格的方式與整數相同。數值的部分有「.2」、「2.」、「2.0」三種呈現方式,實作上區分為兩種判斷方法,([0-9]\*\.[0-9]+)可判斷「.2」和「2.0」這兩種寫法,([0-9]+\.[0-9]\*)則符合「2.」、「2.0」這兩種寫法。此外,若後面加上科學符號表示法 E 或 e,甚至可以不需要小數點,因此加上第三種判斷方法[0-9]+。

雖然純數字的 token (例如:「87」)也符合上述的正規語言定義,但 integer 的 Lex Rule 擺放位置在 float 之上,因此兩者 match 長度相同的情況下,純數字的 token 仍會被辨識為整數。

最後若加上 F 或 f, 代表此浮點數是 float 而不是 double。

#### 7. String Constants

# str \"([^\"\\n\r]|\\['\"\\btnfr0-7])\*\"

開頭和結尾的\"為字串前後的雙引號。字串中可包含多個字元,也可以是空字串,因此在(...)後面加上\*。中間不能出現換行符號、回車符號、單一個「"」或是「\」,這部分以[^\"\\n\r]表示,[^...]代表只 match [...]內以外的字元。而「\t」、「\n」、和「\0」等為特殊字元,且若要在字串中呈現「'」、「"」或「\」必須加上跳脫字元,這些規則以\\['\"\\btnfr0-7]表示。

以上的正規語言定義會將前後的雙引號包含進去·但字串常數其實不包含前後雙引號·因此 scanner 輸出時會省略前後各一個字元。

# invalid\_str \"([^\"\r\n])\*

不合法的字串只有一個雙引號 (例如:"ab)。根據以上規則·「"""」會被判定成一個合法的空字串「""」和一個不合法字串「"」。

#### 8. Characters Constants

# character '([^'\\\n\r]|\\['\"\\btnfr0-7])'

由於規格書上沒有提到字元(例如:'a')屬於哪一類,因此我將其獨立 出來判斷。單引號內基本上只能有一個字元,且此字元不能是換行符號、 回車符號、「'」或是「\」,這部分以[^'\\\n\r]表示。而「\t」、「\n」、和「\0」 等為特殊字元,且若要在字串中呈現「'」、「"」或「\」必須加上跳脫字元, 這些能夠在單引號內放入兩個字元的規則,以\\['\"\\btnfr0-7]表示。

與字串常數相同的是,字元常數不包含前後的單引號,因此 scanner 輸出時會省略前後各一個字元。

# invalid\_char '([^\'\r\n])\*

不合法的字元只有一個單引號(例如:'a 或'ab)。根據以上規則·「'ab'」 會被分別判定成兩個不合法的字元表示法「'ab」和「'」。

# 9. Whitespace

# space [ \t] eol \r?\n

我將 whitespace 區分為 space 和 end of line 來判別·因為兩者的 Lex Rules 不同。space 包含空白和 tabs · 遇到只需要將計算字元數的變數 charCount 加一;若是遇到換行符號(前面可能接著一個回車符號)· 則 須將計算行數的變數 lineCount 加一·並將 charCount 設回 1。

#### 10. Comments

# comment (\/\/[^\n\r]\*)|(\/\\*([^\*]|\\*+[^\*\/])\*\\*+\/)

註解分為可跨行與不可跨行。\/\/[^\n\r]\*辨識不可跨行的註解,「//」的兩個字元前面各需加上一個跳脫字元,後面可出現數個換行符號和回車符號以外的字元。

雖然投影片中提供的可跨行註解的解法為\/\\*(.|\n)\*\\*\/,但此寫法在某些情況下無法辨識出正確的註解結尾,因此我將寫法改成

\/\\*([^\*]|\\*+[^\*\/])\*\\*+\/,思考過程如下:

原寫法:\/\\*(.|\n)\*\\*\/

Problem:若「\*/」後面存在另一個「\*/」,則第一個「\*/」會被.\\n 辨

識,造成註解被錯誤地繼續往後找。

Solution:讓小n辨識出「\*」的後面不能接「/」。

改良寫法 1: \/\\*([^\*]|\\*[^\/])\*\\*\/

Problem: stars 會"成對"被\\*[^\/]辨識·若結尾有偶數個 stars(例如:「\*\*\*\*/」), 會導致正確的註解結尾「\*/」的「\*」必定跟著前面的「\*」一起被\\*[^\/]辨識(也就是「\*\* \*\* /」), 而剩下的「/」又被[^\*]辨識, 造成註解被錯誤地繼續往後找。

Solution:讓[^\/]不能辨識到結尾「\*/」的「\*」。

改良寫法 2:\/\\*([^\*]|\\*[^\*\/])\*\\*\/

Problem:中間若有連續兩個以上的 stars 就會辨識失敗,因為「\*\*」 既不符合\\*[^\*\/],也不符合\\*\/。

Solution:讓\\*辨識連續兩個以上的 stars。

改良寫法 3:\/\\*([^\*]|\\*+[^\*\/])\*\\*\/

Problem: 結尾若有連續兩個以上的 stars 還是會辨識失敗·因為「\*\*/」 既不符合\\*+[^\*\/]·也不符合\\*\/。

Solution:讓\\*\/也可以辨識連續兩個以上的 stars。

最終寫法:\/\\*([^\*]|\\*+[^\*\/])\*\\*+\/

Conclusion: [^\*\/]防止「\*/」的「\*」被辨識成註解內容·\\*+防止中間連續的 stars 辨識失敗·\\*+\/防止結尾連續的 stars 辨識失敗。

### 過程中遇到的問題:

### 1. 如何辨識加減號還是正負號

因為 scanner 會 scan 出長度最長的 token 去進行匹配,因此接在 0-9 前面的+/-可能會被誤判為正負號。在 Java 裡 integer、float、identifier 和 string 是可以作為運算元,接在這四種型態的 tokens 後面的+/-應代表加減號,因此建立一個變數 sub 紀錄前一個傳回給 parser 的 token 是否屬於上述四種類別,若 scan 出一個有帶符號的數字,且 sub 為 True,則將符號作為 operator,並與數字分開印出。

值得注意的是·symbol 中的小括號「(...)」可作為運算式集合運算子· 因此當 scan 出一個「)」時並不能將 sub 的值改為 false。

#### 2. 單行註解辨識問題

我在測試 Test.java 時曾經產生下圖結果:

```
csel32@csel32-virtual-machine:~/Documents/Compiler/lex$ ./demo < Test2.java
" is a "comments".1, "// this is a comment // line */ /* with /* delimiters */ before the end
Line: 3, lst char: 1, "public" is a "reserved word".
Line: 3, lst char: 8, "class" is a "reserved word".
Line: 3, lst char: 14, "Test2" is a "ID".
Line: 3, lst char: 20, "{" is a "symbol".
Line: 4, lst char: 5, "int" is a "reserved word".</pre>
```

可以看到第一行輸出到註解的結尾時·游標會移到此行的開頭繼續輸出,這是因為原本判斷單行註解的正規語言寫法\/\/.\*只排除換行符號·回車符號會被判斷進去。因此我將寫法改成\/\/[^\n\r]\*來避免此狀況。

# 3. Symbol Tables 實作

我以 linked list 實作 symbol tables·每一個 identifier 的名稱與 index 儲存在一個節點中。程式開始執行時,symbol tables 並沒有任何資料,因此 create()只回傳一個空指標。每當偵測到一個 identifier,會呼叫 insert()檢查此 identifier 是否已存在於 symbol tables 中,若無則會動態配置一個新節點來儲存。

insert()並不會不直接呼叫 lookup()來確認 identifier 是否存在,因為 lookup()對於不存在的輸入只會回傳-1,但 insert()需要 symbol tables 中最後一個 identifier 的 index·並將此 index 加一來獲得新節點的 index·也需要將最後一個節點的 next 指標指向新節點,此過程會遍歷過一次 symbol tables,同時檢查 identifier 是否存在。

### 測試檔執行結果:

# Test1.java

```
### Test1.java

resol2gesel2c virtual machine: //Documents/Compiler/lexs ./demo < Test1.java
Line: 2. ist char: 1. "public" is a "reserved word".
Line: 2. ist char: 8. "class" is a "reserved word".
Line: 2. ist char: 4. "public" is a "reserved word".
Line: 3. ist char: 4. "fest1" is a "reserved word".
Line: 3. ist char: 20. "(" is a "symbol".
Line: 3. ist char: 5. "public" is a "reserved word".
Line: 3. ist char: 12. "static" is a "reserved word".
Line: 3. ist char: 12. "static" is a "reserved word".
Line: 3. ist char: 12. "static" is a "reserved word".
Line: 3. ist char: 13. "is a "symbol".
Line: 3. ist char: 13. "" is a "symbol".
Line: 3. ist char: 34. "int" is a "reserved word".
Line: 3. ist char: 34. "int" is a "reserved word".
Line: 3. ist char: 34. "int" is a "reserved word".
Line: 3. ist char: 39. ") " is a "symbol".
Line: 3. ist char: 39. ") " is a "symbol".
Line: 3. ist char: 39. "] " is a "symbol".
Line: 4. ist char: 16. "d is a "lo".
Line: 5. ist char: 18. "is a "operator".
Line: 4. ist char: 16. "is a "operator".
Line: 4. ist char: 16. "is a "operator".
Line: 5. ist char: 27. "is a "symbol".
Line: 7. ist char: 28. "is a "symbol".
Line: 7. ist char: 29. "public" is a "reserved word".
Line: 7. ist char: 29. "public" is a "reserved word".
Line: 7. ist char: 29. "public" is a "reserved word".
Line: 7. ist char: 29. "public" is a "reserved word".
Line: 7. ist char: 29. "public" is a "reserved word".
Line: 7. ist char: 29. "public" is a "reserved word".
Line: 7. ist char: 29. "public" is a "reserved word".
Line: 7. ist char: 3. "c" is a "symbol".
Line: 8. ist char: 3. "c" is a "symbol".
Line: 9. ist char: 3. "c" is a "symbol".
Line: 10. ist char: 3. "c" is a "symbol".
Line: 10. ist char: 3. "c" is a "symbol".
Line: 10. ist char: 3. "c" is a "symbol".
Line: 10. ist char: 3. "c" is a "symbol".
Line: 10. ist char: 3. "c" is a "symbol".
Line: 10. ist char: 3. "c" is a "symbol".
Line: 10. ist char: 3. "c" is a "symbol".
Line: 10. ist char: 3. "c" is a "symbol".
Line: 10. ist char: 3. "c" is a "symbol".
Line: 
                            The symbol table contains:
                            Test1
                            add
```

```
csel32@csel32-virtual-machine:-/Documents/Compiler/Lex$ ./demo < Test2.java
Line: 1, lst char: 1, "// this is a comment // line */ /* with /* delimiters */ before the end" is a "comment".
Line: 3, lst char: 1, "public" is a "reserved word".
Line: 3, lst char: 8, "class" is a "reserved word".
Line: 3, lst char: 14, "Test2" is an "ID".
Line: 3, lst char: 20, "{" is a "symbol".
Line: 4, lst char: 20, "{" is a "symbol".
Line: 4, lst char: 9, "i' is a "is an "ioperator".
Line: 4, lst char: 13, ".l00" is an "integer".
Line: 4, lst char: 13, ".l00" is an "integer".
Line: 5, lst char: 17, "" is a "symbol".
Line: 5, lst char: 5, "double" is a "reserved word".
Line: 5, lst char: 12, "d" is an "ID".
Line: 5, lst char: 12, "d" is an "operator".
Line: 5, lst char: 16, "12.25e6" is a "float".
Line: 5, lst char: 16, "12.25e6" is a "float".
Line: 7, lst char: 12, "static" is a "reserved word".
Line: 7, lst char: 19, "void" is a "reserved word".
Line: 7, lst char: 19, "void" is a "reserved word".
Line: 7, lst char: 19, "void" is a "reserved word".
Line: 7, lst char: 29, ")" is a "symbol".
Line: 7, lst char: 29, ")" is a "symbol".
Line: 7, lst char: 1, "/* this is a comment // line with some /* and
// delimiters */" is a "comment".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, ")" is a "symbol".
Line: 11, lst char: 1, "]" is a "symbol".
Line: 11,
```

# Test3.java

```
Csel32@csel32-virtual-machine:-/Documents/Compiler/lex$ ./demo < Test3.java
Line: 2, 1st char: 1, "public" is a "reserved word".
Line: 2, 1st char: 8, "class" is a "reserved word".
Line: 2, 1st char: 14, "Test3" is an "ID".
Line: 2, 1st char: 20, "{" is a "symbol".
Line: 3, 1st char: 5, "int" is a "reserved word".
Line: 3, 1st char: 9, "A" is an "ID".
Line: 3, 1st char: 9, "A" is an "ID".
Line: 4, 1st char: 5, "int" is a "reserved word".
Line: 4, 1st char: 5, "double" is a "reserved word".
Line: 5, 1st char: 12, "b" is an "ID".
Line: 5, 1st char: 12, "b" is an "ID".
Line: 6, 1st char: 12, "b" is an "ID".
Line: 6, 1st char: 12, "A" is an "ID".
Line: 6, 1st char: 12, "A" is an "ID".
Line: 6, 1st char: 12, "A" is an "ID".
Line: 8, 1st char: 12, "Fest3" is an "ID".
Line: 8, 1st char: 12, "Test3" is an "ID".
Line: 8, 1st char: 18, ")" is a "symbol".
Line: 8, 1st char: 19, "a" is an "ID".
Line: 8, 1st char: 9, "a" is an "ID".
Line: 9, 1st char: 11, "=" is an "operator".
Line: 9, 1st char: 11, "=" is an "operator".
Line: 9, 1st char: 11, "=" is an "operator".
Line: 10, 1st char: 11, "=" is an "operator".
Line: 10, 1st char: 11, "=" is an "operator".
Line: 10, 1st char: 11, "=" is an "operator".
Line: 10, 1st char: 11, "=" is an "operator".
Line: 10, 1st char: 11, "=" is an "operator".
Line: 10, 1st char: 11, "=" is an "operator".
Line: 10, 1st char: 11, "=" is an "operator".
Line: 10, 1st char: 11, "=" is an "operator".
Line: 11, 1st char: 11, "=" is an "operator".
Line: 11, 1st char: 11, "=" is an "operator".
Line: 11, 1st char: 11, "=" is an "operator".
Line: 11, 1st char: 11, "=" is an "operator".
Line: 11, 1st char: 11, "=" is an "operator".
Line: 11, 1st char: 11, "=" is an "operator".
Line: 11, 1st char: 11, "=" is an "operator".
Line: 11, 1st char: 11, "=" is an "operator".
Line: 11, 1st char: 11, "=" is an "operator".
Line: 11, 1st char: 11, "=" is an "operator".
Line: 11, 1st char: 11, "=" is an "operator".
Line: 11, 1st char: 11, "=" is an "operator".
Line: 11, 1st char: 11, "=" is an "operator".
Line:
```